Desafio NPS — Fase 1

Entendimento do Negócio, Target, EDA, Estratégia Preditiva e Modelo (NPS em e-commerce)

Esta etapa corresponde ao **entendimento do negócio** no ciclo CRISP-DM. Antes de qualquer análise ou modelo, o objetivo é transformar uma meta ampla, como "melhorar a satisfação do cliente", em perguntas analíticas concretas, mensuráveis e acionáveis.

Parte 1 — Entendimento do Negócio

1.1. Qual problema de negócio está sendo resolvido?

Dor de negócio: a empresa não sabe quais pontos da jornada de compra produzem clientes insatisfeitos (detratores). Por isso não consegue priorizar investimentos para aumentar a lealdade e a recompra.

Olhando para o processo atual refletido na base, o pedido passa por compra (valor, desconto, parcelamento), entrega (prazo, atraso, frete, tentativas) e pós-venda (contatos, reclamações, tempo de resolução). O NPS mede a percepção que o cliente tem dessa jornada inteira.

Tradução em perguntas analíticas, definindo a unidade de análise, o evento de interesse e o horizonte de tempo:

- **Pergunta descritiva/diagnóstica:** quais fatores operacionais estão associados a notas de NPS mais baixas? Por exemplo, atraso, número de tentativas de entrega, reclamações e tempo de resolução.
- **Pergunta preditiva:** qual a probabilidade de que um **pedido** gere um cliente **detrator** após a experiência de compra? A unidade é o order_id.
- **Pergunta de impacto:** clientes com NPS maior recompram mais em 30 dias (repeat_purchase_30d)?

Metas de negócio x metas analíticas. As métricas técnicas só têm valor se movem os KPIs de negócio, por isso as duas metas são definidas juntas:

- **Meta de negócio:** reduzir a proporção de detratores e aumentar a taxa de recompra.
- **Meta analítica:** identificar e quantificar os *drivers* do NPS e, mais adiante, prever detratores com antecedência suficiente para agir antes da pesquisa.

Os cuidados com o uso da variável-alvo, como vazamento de dados e viés, estão detalhados na Parte 2.

1.2. Por que o NPS é importante para um e-commerce?

- **A relação é digital e a troca de loja custa pouco.** Mudar de concorrente exige um clique. A lealdade vem quase só da experiência, e o NPS é um termômetro direto dela.
- **É um indicador antecedente.** Faturamento e churn mostram o problema depois que ele aconteceu. O NPS pode sinalizar insatisfação antes de ela aparecer na receita.
- **Mede a jornada de ponta a ponta.** No e-commerce, boa parte da experiência acontece fora do site: transportadora, entrega, SAC. O NPS capta o efeito dessas etapas, que métricas de site como conversão não enxergam.
- **É simples e comparável.** Uma pergunta só, fácil de acompanhar no tempo, por região e por segmento, e de comparar com o mercado.

- **Tem limitações.** Uma nota única não explica o motivo da insatisfação, e a nota sofre viés de resposta, já que clientes muito satisfeitos ou muito insatisfeitos respondem mais. Por isso a análise precisa cruzar o NPS com variáveis operacionais, que é exatamente o que a base permite.

1.3. Quais áreas se beneficiam dos insights?

A tabela liga cada área às variáveis da base que a afetam, para que os insights sejam acionáveis. Um insight só gera valor se alguma área souber o que fazer com ele.

Área	Variáveis da base	Exemplo de insight / ação
Logística	delivery_time_days, delivery_delay_days, delivery_attempts, customer_region	A partir de quantos dias de atraso o NPS cai mais? Quais regiões precisam de outra transportadora ou de um CD mais próximo?
Atendimento (SAC)	customer_service_contacts, resolution_time_days, complaints_count	Definir um SLA de resolução e acionar contato proativo quando houver atraso.
Pricing / Comercial	freight_value, discount_value, order_value, payment_installments	O frete caro derruba a satisfação? Os descontos compensam experiências ruins?
CRM / Marketing	customer_tenure_months, customer_age, repeat_purchase_30d	Montar campanhas de recompra para promotores e de recuperação para detratores, segmentadas por tempo de relacionamento.
Produto / Experiência	items_quantity, csat_internal_score	Pedidos com muitos itens geram mais problemas? O CSAT interno está alinhado com o NPS?
Diretoria / Finanças	NPS agregado e recompra	Priorizar investimentos pelo impacto estimado na receita recorrente.

1.4. Reflexão: como o NPS impacta...

Recompra

O mecanismo é direto: experiência boa leva a confiança, e confiança leva a uma nova compra. Promotores tendem a voltar com mais frequência e a ter maior *lifetime value*. Detratores tendem a sair, e o custo de reconquistá-los é alto. A base permite testar essa hipótese, porque repeat_purchase_30d aparece junto com nps_score. Uma pergunta concreta para as próximas fases é se a taxa de recompra difere entre promotores, neutros e detratores. Essa associação ainda não foi calculada, e os números só vão aparecer na análise exploratória. Vale lembrar também que a relação pode ter confundidores: clientes antigos (customer_tenure_months) podem ter, ao mesmo tempo, NPS maior e recompra maior.

Boca a boca

A pergunta do NPS é literalmente sobre recomendação. No e-commerce, o boca a boca hoje é majoritariamente digital: avaliações de produto, redes sociais e sites de reputação como o Reclame Aqui. Esse efeito é assimétrico. Um detrator costuma espalhar uma experiência ruim mais do que um promotor espalha uma boa, e reclamações públicas afetam a conversão de clientes que ainda nem compraram. Por isso, reduzir detratores costuma valer mais do que aumentar promotores na mesma proporção.

Market share

O efeito é indireto e cumulativo. Recompra maior significa mais receita por cliente. Boca a boca positivo reduz o custo de aquisição de clientes (CAC), porque parte dos clientes chega por indicação e não por mídia paga. Com CAC menor e LTV maior, a empresa pode crescer mais rápido que concorrentes com NPS pior, e ganha participação de mercado. Em um setor com custo de troca quase zero e muitos competidores, como o e-commerce brasileiro, a experiência é um dos poucos diferenciais que não se copiam com facilidade. Uma ressalva honesta: a base atual não permite medir market share. Essa relação é uma hipótese de negócio que dependeria de dados externos para ser validada.

1.5. Indicadores de mercado que complementariam a análise

A base é exclusivamente interna. Os indicadores abaixo dariam contexto competitivo e permitiriam dizer se os resultados da empresa são bons ou ruins em relação ao mercado.

- **Benchmarks de NPS do setor:** compará-los com o NPS da empresa mostra se uma nota baixa é um problema próprio ou característico do segmento. Exemplos são pesquisas setoriais e consultorias de CX. O dado deve ser de varejo online brasileiro, porque o NPS varia muito entre setores e países.
- **SLA logístico de mercado:** prazo médio de entrega da concorrência e dos marketplaces, prazos dos Correios e das principais transportadoras por região, e taxa de entrega no prazo (OTD). Isso responde se o delivery_time_days da empresa é competitivo.
- **Reputação pública:** nota e índice de solução no Reclame Aqui, avaliações em Google e marketplaces, e reputação em selos como Ebit|Nielsen.
- **Concorrência:** frete grátis e política de frete dos concorrentes, já que isso afeta a percepção de freight_value, além de preço relativo e condições de parcelamento.
- **Indicadores de negócio internos complementares:** taxa de churn, CAC, LTV, ticket médio e taxa de devolução. Eles ligam o NPS a resultados financeiros.
- **Contexto macro e sazonal:** datas como Black Friday e Natal, que aumentam atrasos e reclamações, e a confiança do consumidor.

Parte 2 — Definição da Target

2.1. Qual variável representa a satisfação do cliente?

A variável-alvo é o **nps_score**, a nota de 0 a 10 que o cliente dá à pergunta de recomendação após a experiência de compra. Ela é a expressão direta da percepção do cliente. As demais colunas da base descrevem o que aconteceu no pedido (prazo, atraso, frete, atendimento), e não como o cliente se sentiu.

Do ponto de vista de negócio, a nota pode ser usada de duas formas, e a escolha muda a pergunta que respondemos:

- **Nota contínua (0 a 10):** responde "quanto cada fator aumenta ou reduz a satisfação". É a forma mais rica em informação e serve bem para entender os *drivers* da nota.
- **Categoria do cliente (detrator, neutro, promotor):** é como o próprio indicador NPS é calculado (% de promotores menos % de detratores). A versão mais acionável é um alvo binário, "o cliente é detrator?" (nota de 0 a 6), porque é sobre os detratores que as áreas conseguem agir: recuperar o cliente, ressarcir o frete, acionar o SAC.

A recomendação é tratar a **nota** como alvo para a análise explicativa e a **condição de detrator** como alvo para uma futura priorização de clientes. Ambas derivam da mesma variável.

2.2. Por que ela foi escolhida?

- **É a voz do cliente.** É a única variável declarada pelo próprio cliente sobre a experiência. As variáveis operacionais são causas possíveis da satisfação, não a satisfação.
- **Resume a jornada inteira.** Uma nota única reflete compra, entrega e pós-venda ao mesmo tempo, o que permite comparar o peso relativo de cada etapa.
- **Está ligada a resultados de negócio.** A pergunta é sobre recomendação, que se conecta a recompra, boca a boca e custo de aquisição, como discutido na Parte 1.
- **É um padrão de mercado.** O NPS pode ser acompanhado no tempo e comparado com concorrentes e benchmarks, coisa que um indicador interno não permite.

Por que não as alternativas:

- **csat_internal_score:** é um score interno com metodologia desconhecida (escala, momento e forma de cálculo). Serve como validação cruzada do NPS, mas não como alvo principal.
- **repeat_purchase_30d:** é comportamento, e não percepção. É influenciada por fatores alheios à satisfação, como necessidade, sazonalidade ou preço. Faz mais sentido como **resultado de negócio** que o NPS ajuda a explicar, e é um bom candidato a alvo secundário.
- **complaints_count:** só capta os casos extremos negativos. A maioria dos clientes insatisfeitos não reclama; simplesmente não volta.

2.3. Em que momento da jornada essa informação é coletada?

Segundo o dicionário de dados, a nota é coletada **após a experiência de compra**, o que, em e-commerce, normalmente significa depois da entrega. Esse momento define o que pode e o que não pode ser usado para explicar ou prever a nota:

- **Antes da coleta (podem explicar a nota):** perfil do cliente (idade, região, tempo de relacionamento), dados do pedido (valor, itens, desconto, parcelas, frete) e dados da entrega (prazo, atraso, tentativas).
- **Momento incerto (precisam ser validados):** contatos com o atendimento, tempo de resolução, reclamações e CSAT interno. Se um problema foi aberto ou resolvido depois da pesquisa, ele não pode ter influenciado a nota.
- **Depois da coleta (não podem explicar a nota):** recompra em 30 dias. Ela é consequência da experiência, não causa da nota.

Uma pergunta importante para o negócio: a pesquisa é disparada no mesmo momento para todos os clientes? Se alguns respondem antes da entrega e outros depois, as notas não são comparáveis entre si.

2.4. Existe algum risco de usar essa variável de forma inadequada?

Sim. Os principais riscos são:

- **Vazamento de dados (data leakage).** Usar como explicativas variáveis registradas depois da pesquisa, como repeat_purchase_30d ou, possivelmente, reclamações e CSAT. O modelo pareceria ótimo na análise, mas não funcionaria na prática, porque essas informações não existem no momento em que precisamos agir.
- **Tratar a nota como uma escala contínua perfeita.** A nota é ordinal: a distância entre 6 e 7 (de detrator para neutro) não tem o mesmo significado de negócio que a distância entre 3 e 4. Além disso, a **média das notas não é o NPS**. A média pode subir enquanto o NPS cai, se os clientes neutros migrarem para detratores e os detratores melhorarem um pouco.
- **Qualidade da própria variável.** Na base, a nota é registrada com casas decimais (por exemplo, 4,4), embora uma pesquisa de NPS só aceite números inteiros. Isso indica que a variável pode ter sido transformada, calculada ou simulada. Também deixa ambíguo o corte de categorias: uma

nota de 6,5 seria detrator ou neutro? É preciso entender com o negócio como a nota é gerada antes de classificar os clientes. A base também não tem valores ausentes, o que é incomum em pesquisas reais e sugere que os não respondentes foram excluídos ou imputados.

- **Viés de resposta.** Só responde quem quer, e os clientes nos extremos (muito satisfeitos ou muito insatisfeitos) respondem mais. A nota média da amostra pode não representar toda a base de clientes.
- **Confundir associação com causa.** Se clientes com nota alta recompram mais, isso não prova que aumentar a nota aumenta a recompra: clientes antigos, por exemplo, podem ter as duas coisas por outro motivo.
- **Transformar o indicador em meta de equipe.** Quando uma área é cobrada pelo NPS, surgem incentivos a manipular a pesquisa, como escolher quem recebe o questionário ou pedir nota 10 ao cliente. O indicador deixa de medir a satisfação real.
- **Nível de análise.** Na base, cada cliente aparece em um único pedido, então a nota é por pedido e por cliente ao mesmo tempo. Em uma base real com vários pedidos por cliente, seria preciso decidir se o alvo é a experiência do pedido ou a relação com o cliente, e garantir que o mesmo cliente não apareça ao mesmo tempo nos dados de treino e de teste.

Parte 3 — Análise Exploratória dos Dados (EDA)

Esta parte traduz os resultados da análise exploratória (notebook **EDA_NPS_Fase1_v2.ipynb**, com 2.500 pedidos) para a linguagem de quem toca a operação. A ideia é responder: *onde a experiência quebra e o que fazer a respeito*.

> **Em uma frase:** o cliente não fica insatisfeito por causa do preço, do frete ou de quem ele é. Ele fica insatisfeito **quando a entrega atrasa e quando precisa reclamar**.

Ponto de partida. De cada 100 clientes, cerca de **84 são detratores** (deram nota abaixo de 7), 11 são neutros e só 4 são promotores. O NPS da empresa é **−80**: para cada cliente que recomendaria a loja, existem 19 que falariam mal dela. Isso vale para todas as regiões e todos os perfis de cliente, então é um problema da operação como um todo, e não de um grupo específico. E não é efeito do acaso: com 95% de confiança, o NPS fica entre **−82 e −78**.

3.1. Quais fatores parecem mais críticos para a satisfação?

Quatro fatores explicam a maior parte da nota. Todos estão ligados a **coisas que deram errado** na jornada, não a características da compra ou do cliente:

Prioridade	Fator	O que os dados mostram	Peso
1	**Atraso na entrega**	Cada dia de atraso tira quase **1 ponto** da nota (numa escala de 0 a 10). A nota média cai de 6,9 (entrega no prazo) para 1,3 (5 dias ou mais de atraso).	Muito alto
2	**Reclamações**	Cada reclamação tira cerca de 0,4 ponto. Clientes sem reclamação dão, em média, nota 8,5; com 4 reclamações, 4,2.	Alto
3	**Contatos com o SAC**	Quem precisou falar com o SAC dá nota menor: nota típica de 5,5 para quem não ligou contra 4,0 para quem ligou.	Médio
4	**Demora para resolver**	Cada dia de espera pela solução tira cerca de 0,15 ponto. Somando os 11 dias de demora máxima, a perda passa de 1,5 ponto.	Médio

O que NÃO afeta a satisfação: valor do pedido, frete, desconto, parcelamento, quantidade de itens, região, idade e tempo de cliente. Em todos esses casos a nota é praticamente a mesma, qualquer que

seja o valor, e os testes estatísticos confirmam que as pequenas diferenças entre esses grupos estão dentro do que o acaso explicaria (seção 3.5).

> **Descoberta-chave para operações:** o **prazo de entrega em si não importa**. Um pedido entregue em 14 dias, conforme prometido, recebe a mesma nota que um entregue em 2 dias. O que o cliente pune é a **promessa quebrada**: 2 dias de atraso derrubam a nota, um prazo longo e cumprido, não.

3.2. O que mais gera detratores?

- **O atraso é a principal fábrica de detratores.** 89% dos pedidos atrasam pelo menos 1 dia, e 93% dos detratores (1.966 de 2.109) tiveram atraso. Entre os pedidos que atrasaram 3 dias ou mais, 98% viraram detratores.
- **As reclamações vêm logo atrás.** 89% dos detratores registraram 3 ou mais reclamações. Parte delas provavelmente é consequência do próprio atraso: o cliente reclama porque o pedido não chegou.
- **Atraso e reclamação juntos são fatais.** Pedidos com 3 ou mais dias de atraso **e** 5 ou mais reclamações (17% da base) têm praticamente 100% de detratores.
- **Só eliminar o atraso não resolve tudo.** Mesmo entre os pedidos entregues no prazo, metade dos clientes (52%) ainda é detratora, puxada pelas reclamações e pelo atendimento. Uma estimativa simples indica que, se nenhum pedido atrasasse, a fatia de detratores cairia de 84% para algo em torno de 65%. É um ganho grande, mas não suficiente: atendimento e prevenção de problemas precisam andar junto com a logística.

3.3. Existe algum "ponto de ruptura" na experiência do cliente?

Sim, e existem dois. Eles aparecem no gráfico abaixo: a proporção de detratores não sobe de forma gradual, ela dá **saltos** em pontos específicos.

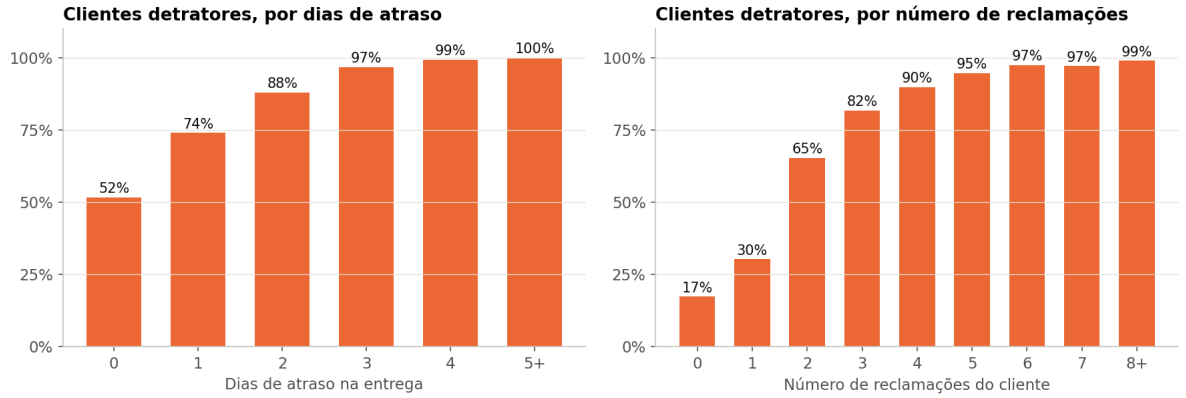


Figura 1 — Percentual de clientes detratores por dias de atraso (esquerda) e por número de reclamações (direita).

Ruptura	O que acontece	Leitura para a operação
1º dia de atraso	É a maior queda de toda a jornada: os detratores vão de 52% para 74%, e o NPS cai de −34 para −67 (−33 pontos) em um único dia.	O dano começa no **primeiro** dia. Avisar o cliente antes de o prazo estourar vale mais do que qualquer ação depois.
3º dia de atraso	A partir daqui, 97% a 100% dos clientes são detratores. Não há mais "satisfação a perder".	É o **ponto sem volta**. Do 3º dia em diante, só restam ações de recuperação (compensação, contato pessoal).
2ª reclamação	Com 1 reclamação, 30% são detratores; com 2, salta para 65%. O NPS vai de −9 para −54 (−45 pontos).	O cliente **tolera um problema, mas não dois**. Resolver de vez na primeira reclamação é decisivo.

> **Janela de ação:** prevenir antes do 1º dia de atraso e antes da 2ª reclamação. Entre o 1º e o 2º dia de atraso ainda há o que recuperar; depois do 3º, a experiência já está perdida.

3.4. Que tipo de cliente tende a ter NPS mais alto ou mais baixo?

Não existe um "tipo de cliente" mais exigente. Jovens e idosos, clientes novos e antigos, quem gasta muito e quem gasta pouco, de qualquer região: todos dão notas parecidas, com NPS entre −84 e −78. O que separa clientes satisfeitos de insatisfeitos é **a experiência que tiveram**, não quem eles são:

Experiência do cliente	Pedidos	% da base	Nota média	NPS
Entregue no prazo e sem contato com o SAC	65	2,6%	8,2	**+18**
Entregue no prazo e com até 2 reclamações	122	4,9%	7,8	−2
Entregue no prazo (todos)	277	11,1%	6,9	−34
Atraso de 1 a 2 dias	1.261	50,4%	5,1	−77
Atraso de 3 dias ou mais	962	38,5%	2,8	−98
Atraso de 3+ dias e 5+ reclamações	419	16,8%	2,0	**−100**

- **NPS mais alto:** cliente que recebeu no prazo e não precisou acionar o atendimento. É o único grupo com NPS positivo, mas representa menos de 3% dos pedidos (65 casos, um grupo pequeno, então o número exato deve ser lido com cautela).
- **NPS mais baixo:** cliente que esperou 3 dias ou mais além do prometido e teve de reclamar várias vezes. Nesse grupo, ninguém recomenda a empresa.
- **Implicação:** campanhas segmentadas por perfil ou descontos para "públicos insatisfeitos" tendem a não funcionar, porque o público não é o problema. O caminho é **melhorar a experiência de todos**, a começar pela entrega.

3.5. Como sabemos que não é acaso: as hipóteses testadas

Antes da análise, registramos oito hipóteses sobre o que poderia explicar a nota. Cada uma foi colocada à prova com **testes estatísticos**, que respondem a uma pergunta simples: *a diferença que estamos vendo é grande demais para ser coincidência?* A tabela resume o veredito em linguagem de negócio:

Hipótese	Veredito	O que os dados mostram
H1 — O atraso derruba a nota	✅ **Confirmada**	Sem atraso, nota média de 6,9; com atraso, 4,1. Uma diferença de quase 3 pontos, com chance praticamente nula de ser acaso.
H2 — Contatos e reclamações derrubam a nota	✅ **Confirmada**	Quem não acionou o SAC dá nota 5,5; quem acionou, 4,0. Quanto mais reclamações, menor a nota.
H3 — Resolução lenta derruba a nota	✅ Confirmada (efeito moderado)	Cada dia de espera pesa, mas bem menos que o atraso.
H4 — Frete caro e pouco desconto derrubam a nota	❌ Sem efeito prático	O frete aparece no limite do teste, mas explica cerca de 0,2% da variação da nota. O desconto não tem efeito.
H5 — A nota muda entre regiões	❌ Refutada	As cinco regiões têm a mesma proporção de detratores (83% a 86%); as diferenças são compatíveis com o acaso.

Hipótese	Veredito	O que os dados mostram
H6 — O perfil do cliente muda a nota	❌ Refutada	Idade e tempo de casa não têm relação com a nota.
H7 — Quem dá nota alta recompra mais	⚠️ Inconclusiva	Todos que deram nota 8 ou mais recompraram e ninguém abaixo de 8 recomprou. Um corte tão exato indica que a recompra foi **calculada a partir da própria nota**, então não serve como evidência.
H8 — CSAT e NPS medem a mesma coisa	❌ Refutada	O CSAT reage à demora na resolução do atendimento; o NPS reage principalmente ao atraso na entrega.

- **Atenção a um detalhe técnico com consequência prática:** com 2.500 pedidos, até efeitos minúsculos podem "passar" num teste. Por isso, cada veredito considera também o **tamanho** do efeito, e não só o resultado do teste. O frete é o exemplo: estatisticamente detectável, mas irrelevante para o negócio.
- **Sinais de que a base foi simulada:** além das notas com casas decimais, várias informações seguem padrões regulares demais para uma operação real (quantidade de itens, idade e prazo de entrega igualmente distribuídos; atrasos e contatos seguindo exatamente uma curva teórica). As conclusões valem para esta base; no mundo real, os efeitos tendem a ser menores e mais ruidosos.

3.6. Recomendações para a gerência de operações

1. **Transformar "entrega no prazo" no principal indicador ligado ao NPS**, com meta e acompanhamento por transportadora e centro de distribuição.
2. **Prometer prazos realistas no checkout.** Como o prazo longo não incomoda e o atraso sim, é melhor prometer 10 dias e cumprir do que prometer 7 e atrasar.
3. **Criar um alerta no 1° dia de atraso**, com aviso proativo ao cliente e um novo prazo, antes que ele precise reclamar.
4. **Tratar como prioridade de recuperação** os pedidos com 3 ou mais dias de atraso ou com 2 ou mais reclamações, que são praticamente detratores garantidos.
5. **Resolver na primeira reclamação**, porque é na segunda que o cliente rompe com a empresa.

> **Cuidados na leitura:** os dados mostram o que **anda junto** com a nota, o que não prova causa e efeito. Além disso, a base tem sinais de ter sido simulada (notas com casas decimais, padrões regulares demais), então, no mundo real, os efeitos tendem a ser menores. As ações acima devem ser validadas com um teste controlado (teste A/B) antes de serem adotadas em toda a operação.

Parte 4 — Antecipando a satisfação com um modelo preditivo

4.1. Como um modelo preditivo apoiaria a empresa

Hoje a empresa só descobre que um cliente está insatisfeito **depois** da pesquisa, quando a experiência já está perdida. E só para quem responde. Um modelo preditivo inverte essa lógica: ele estima, **durante a jornada**, a chance de cada cliente se tornar detrator, usando os sinais que a operação já registra (atraso, reclamações, contatos). Com isso, a empresa:

- **Age antes da pesquisa**, no momento em que ainda dá para recuperar a experiência (Parte 3: a janela é entre o 1° e o 2° dia de atraso).

- **Prioriza recursos:** o SAC e o CRM concentram esforço nos clientes de maior risco, em vez de tratar todos igualmente.
- **Enxerga 100% dos clientes**, inclusive os que nunca respondem à pesquisa.

4.2. Regressão ou classificação?

Critério	Regressão (nota de 0 a 10)	Classificação (detrator × não detrator)
Pergunta respondida	Qual nota este cliente vai dar?	Qual a chance de este cliente ser detrator?
Saída	Um número contínuo (ex.: 5,8)	Uma probabilidade (ex.: 92%) e uma classe
Pontos fortes	Mais informação; mostra **quanto** cada fator custa em pontos de nota, o que é útil para simular impacto (ex.: "reduzir 1 dia de atraso vale +0,95 ponto")	Alinhada à **decisão** (agir ou não agir); o próprio NPS é calculado por categorias; a probabilidade permite **ordenar** os clientes por risco
Pontos fracos	A nota é limitada a 0–10 (há muitos zeros), o que um modelo linear não respeita: na EDA, a regressão previu 33 notas abaixo de zero. O erro médio de 1,3 ponto (MAE; RMSE de 1,66) confunde a fronteira entre 6,9 (detrator) e 7,0 (neutro); e a ação de negócio não é contínua	Perde a nuance dentro de cada categoria; a escolha do limiar exige critério de negócio; a classe "não detrator" é minoritária (16%)
Métricas	MAE, RMSE, R^2	AUC, recall, precisão, F1, matriz de confusão, calibração

4.3. Estratégia adotada

> **Modelo principal: classificação do risco de detrator** (nota < 7), gerando uma probabilidade de 0% a 100% para cada pedido. **Modelo de apoio: regressão da nota**, usada para explicar e quantificar o impacto de cada fator, e não para disparar ações.

Justificativa de negócio.

- A decisão operacional é binária: acionar ou não o SAC/CRM para um cliente. Uma probabilidade de risco responde exatamente a essa pergunta e permite definir regras simples, como "risco acima de 80% → contato proativo".
- O indicador que a diretoria acompanha (NPS) é a diferença entre **proporções** de promotores e detratores. Reduzir detratores move o NPS diretamente.
- A regressão continua valiosa para a gestão: ela traduz cada melhoria operacional em pontos de nota e ajuda a priorizar investimentos (ex.: reduzir atraso rende mais que acelerar a resolução).

Justificativa técnica.

- A nota tem problemas que afetam mais a regressão do que a classificação: é limitada entre 0 e 10, tem acúmulo de zeros (158 notas exatamente iguais a 0), não segue uma distribuição normal (teste de Shapiro-Wilk com $p < 0{,}001$) e vem com casas decimais de origem incerta. Prever "abaixo ou acima de 7" é mais robusto do que acertar a nota exata.
- A EDA mostrou relações **não lineares**: o risco satura a partir de 3 dias de atraso e dá um salto na 2ª reclamação. Modelos de classificação baseados em árvores capturam esses "degraus" naturalmente.
- **Atenção ao desbalanceamento invertido.** Como 84% dos clientes são detratores, um modelo que chutasse "todo mundo é detrator" teria 84% de acerto sem servir para nada. Por isso, a **acurácia não será usada** como métrica principal. O foco será a capacidade de **ordenar** clientes por risco (AUC) e a precisão e o recall na faixa de risco em que a empresa vai agir.

4.4. Em que momento prever

A EDA mostra que **o poder de previsão depende do momento da jornada**, porque os fatores decisivos só existem depois que o pedido sai para entrega. O modelo deve, portanto, ser um **escore atualizado ao longo da jornada**, e não uma previsão única no momento da compra:

Momento	Informação disponível	Quanto da nota se consegue explicar*	Uso
Na compra	Perfil do cliente e dados do pedido	Menos de 1%	Não vale um modelo aqui: nada do que se sabe na compra antecipa a nota
Durante a entrega	+ atraso e tentativas de entrega	Cerca de 36%	**Momento-chave**: o atraso já aparece e ainda dá tempo de agir
Pós-venda	+ contatos, reclamações e tempo de resolução	Cerca de 56%	Refina o risco e aciona recuperação; só vale se esses registros ocorrerem antes da pesquisa

** R^2 de regressões lineares exploratórias ajustadas na própria base durante a EDA; servem para comparar os momentos, não como desempenho esperado do modelo final.*

4.5. Como o projeto seria construído

1. **Alvo e variáveis.** Alvo: detrator = nota < 7. Entram apenas variáveis disponíveis **no momento da previsão**. Ficam fora a recompra em 30 dias (posterior à pesquisa e, nesta base, derivada da própria nota) e o CSAT interno (outra medida de satisfação, não uma causa). Novas variáveis derivadas da EDA: "houve atraso", "atraso ≥ 3 dias", "2 ou mais reclamações" e atraso proporcional ao prazo prometido.
2. **Divisão dos dados.** Treino e teste estratificados pela categoria de NPS, com validação cruzada. Em dados reais com datas, validação **temporal** (treinar no passado e testar no futuro), que reproduz o uso real do modelo.
3. **Modelos comparados.** (a) uma **regra simples** como referência mínima ("atrasou → risco alto"); (b) **regressão logística**, interpretável, que explica ao gerente por que o cliente foi sinalizado; (c) **modelos de árvores** (Random Forest ou Gradient Boosting), que capturam os pontos de ruptura. O modelo mais complexo só vence se superar os mais simples com folga.
4. **Avaliação técnica e de negócio.** Técnica: AUC, precisão, recall e calibração (um risco de 90% deve corresponder a 90% de detratores de fato). Negócio: quantos detratores a ação evitaria, a que custo. O **limiar** de acionamento é escolhido comparando o custo da ação (contato, cupom) com o valor do cliente recuperado.
5. **Explicabilidade.** Para cada cliente sinalizado, mostrar os principais motivos do risco (ex.: "3 dias de atraso + 2 reclamações"). Isso dá confiança à operação e orienta a ação certa.
6. **Implantação.** Escore recalculado diariamente para os pedidos em andamento, com gatilhos para o SAC e o CRM e um painel para a gerência de operações.
7. **Prova de valor com teste A/B.** O modelo indica **quem** está em risco, mas não prova que a ação funciona. Um teste A/B com cerca de 754 pedidos atrasados por grupo (dimensionado na EDA) mede se o contato proativo realmente reduz detratores.
8. **Monitoramento.** Acompanhar se o desempenho se mantém (mudanças de transportadora, sazonalidade e novas políticas alteram os padrões) e retreinar periodicamente. Manter sempre um **grupo de controle** sem intervenção, porque as próprias ações mudam as notas futuras e podem "enganar" o modelo.

4.6. Metas de negócio e metas analíticas

Meta de negócio (o destino)	Meta analítica (o caminho)
Reduzir a proporção de detratores entre pedidos atrasados (ex.: −5 pontos percentuais, de 88% para 83%)	Ordenar bem os clientes por risco: AUC claramente superior à da regra simples
Agir antes da pesquisa em todos os pedidos de alto risco	Alto recall na faixa de risco acionada, ou seja, poucos detratores "escapando" sem ação
Usar bem o tempo do SAC e o orçamento de compensação	Boa precisão no limiar escolhido, ou seja, poucos contatos com quem não precisava
Subir o NPS da empresa	Probabilidades calibradas, para estimar o NPS esperado antes da pesquisa

4.7. Riscos e cuidados

- **Vazamento de dados:** usar variáveis registradas depois da pesquisa daria um modelo excelente no papel e inútil na prática. Cada variável precisa ter data de registro conhecida.
- **Base simulada:** nesta base, um modelo aprenderia as regras usadas para gerar os dados e teria desempenho otimista. Os resultados precisam ser revalidados com dados reais.
- **Viés de resposta:** o modelo é treinado com quem respondeu à pesquisa, mas será aplicado a todos os clientes. É preciso verificar se quem responde se parece com quem não responde.
- **Uso indevido:** o escore não deve ser usado para escolher quem recebe a pesquisa (enviar só aos clientes "felizes"), o que inflaria o NPS artificialmente. A finalidade é melhorar a experiência, não maquiar o indicador.
- **Privacidade e ética:** usar apenas dados operacionais do pedido, sem atributos sensíveis, em conformidade com a LGPD. A EDA mostrou que idade e região nem ajudam a prever, então não há motivo para usá-los.

Parte 5 — Modelo preditivo: objetivo, avaliação e aplicação

Esta parte apresenta a implementação da estratégia descrita na Parte 4, com as fases de **modelagem**, **avaliação** e **implantação** do CRISP-DM. Todos os números abaixo vêm da execução do notebook de modelagem sobre a base do desafio (2.500 pedidos).

5.1. Objetivo do modelo

> **Objetivo:** estimar, para cada pedido, a **probabilidade de o cliente se tornar detrator** (nota de 0 a 6) **antes** de a pesquisa de NPS chegar, para que o SAC e o CRM possam agir enquanto a experiência ainda pode ser recuperada.

Dimensão	Definição
Dor de negócio	84% dos clientes são detratores (NPS ≈ −80) e a empresa só descobre a insatisfação depois que ela aconteceu.
Meta de negócio	Reduzir a proporção de detratores com ação proativa, usando o orçamento e a capacidade do SAC/CRM que existem hoje.
Meta analítica	Classificador com **AUC-ROC superior à regra simples** "atrasou, é risco" (0,784) e com **precisão acima da taxa base** de 84,4% na faixa de pedidos acionada.
Saída do modelo	Um **score de risco** de 0 a 1 por pedido, convertido em faixa (Alto, Médio, Baixo) e em ação sugerida.

5.2. Como o modelo foi construído

Etapa	Decisão
Variável-alvo	detrator = 1 se a nota for de 0 a 6. A classe positiva é a maioria (84,4%), o que torna a acurácia enganosa.
Variáveis de entrada	Perfil, pedido, entrega e atendimento: 13 numéricas e a região (convertida em dummies). **Excluídas por vazamento:** recompra em 30 dias (é 0% para toda nota abaixo de 8 e 100% a partir de 8, ou seja, foi calculada a partir da nota) e CSAT interno (outra medida de satisfação).
Dois cenários	**A · momento da entrega:** só perfil, pedido e entrega. **B · após o pós-venda:** soma contatos com o SAC, reclamações e tempo de resolução. Os dois existem porque não sabemos se as reclamações são registradas antes da pesquisa.
Separação dos dados	80% treino (2.000) e 20% teste (500), estratificada (84,4% de detratores nas duas partes). Escolha do modelo por validação cruzada estratificada de 5 partes, só no treino.
Preparação	Pipeline com imputação pela mediana, padronização e dummies, ajustado só no treino para evitar vazamento.
Modelos comparados	Modelo "bobo" (sempre detrator), regra de atraso ≥ 1 dia, Regressão Logística, Árvore de Decisão e Random Forest.

5.3. Avaliação dos resultados

Comparação dos modelos

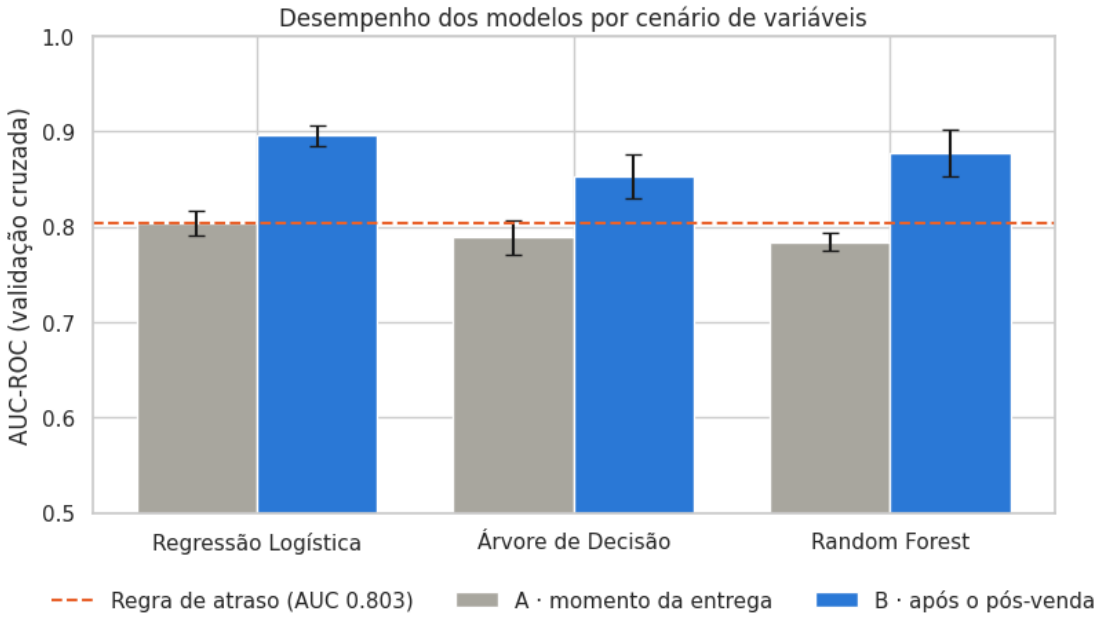


Figura — AUC-ROC na validação cruzada (média ± desvio) por modelo e cenário. A linha tracejada é a regra de atraso.

- **Com o que se sabe na entrega (cenário A), nenhum modelo supera a regra simples:** as AUCs ficam entre 0,78 e 0,80, em cima da regra (0,80 no treino). O atraso já carrega quase toda a informação disponível nesse momento.
- **Os dados de atendimento (cenário B) são o que dá valor ao modelo:** a AUC da Regressão Logística sobe de 0,804 para **0,896** na validação cruzada. Trocar de algoritmo muda poucos centésimos; acrescentar o atendimento muda cerca de 9 pontos.
- **Modelo escolhido: Regressão Logística do cenário B.** Teve a maior AUC média, a menor variação entre as partes (± 0,011), é leve e é interpretável. Ao contrário do que se esperava na Parte 4, os

modelos de árvores não trouxeram ganho: as relações são aproximadamente lineares nesta base.

Desempenho no conjunto de teste (500 pedidos nunca vistos)

Modelo	Acurácia	Precisão	Recall	F1	AUC-ROC
Modelo bobo (sempre detrator)	0,844	0,844	1,000	0,915	0,500
Regra: atraso ≥ 1 dia	0,834	0,881	0,929	0,904	0,784
Logística · cenário A	0,840	0,861	0,967	0,911	0,779
Logística · cenário B	**0,858**	**0,886**	**0,955**	**0,919**	**0,868**
Random Forest · cenário B	0,862	0,872	0,981	0,923	0,869

Métricas no corte padrão de 0,5. A acurácia e o F1 do modelo bobo mostram por que essas métricas não servem para comparar modelos neste problema.

- A Logística do cenário B atinge **AUC de 0,868**, contra 0,784 da regra, e **precisão de 88,6%**, acima da taxa base. A Random Forest empata (0,869), então fica o modelo mais simples.
- A queda de 0,896 (validação cruzada) para 0,868 (teste) é compatível com a variação natural de 500 pedidos e não indica sobreajuste preocupante.
- **Matriz de confusão (corte 0,5):** 403 detratores encontrados, 19 que escaparam, 52 alarmes sem necessidade e apenas 26 satisfeitos reconhecidos. O modelo marca 91% dos pedidos como risco: com 84% de detratores, o corte de 0,5 é baixo demais para uso prático.

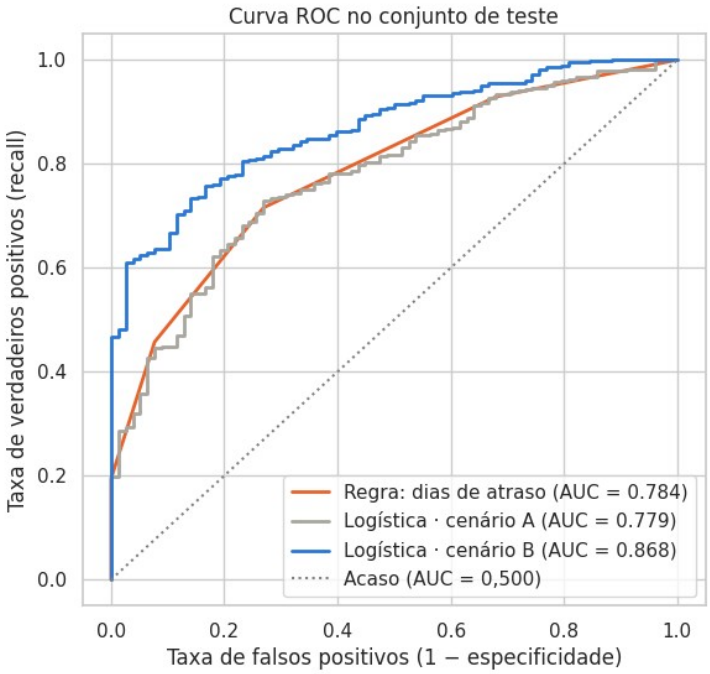


Figura — Curva ROC no teste. O cenário A (cinza) se sobrepõe à regra de atraso; o cenário B (azul) fica acima em toda a extensão.

O que pesa no risco

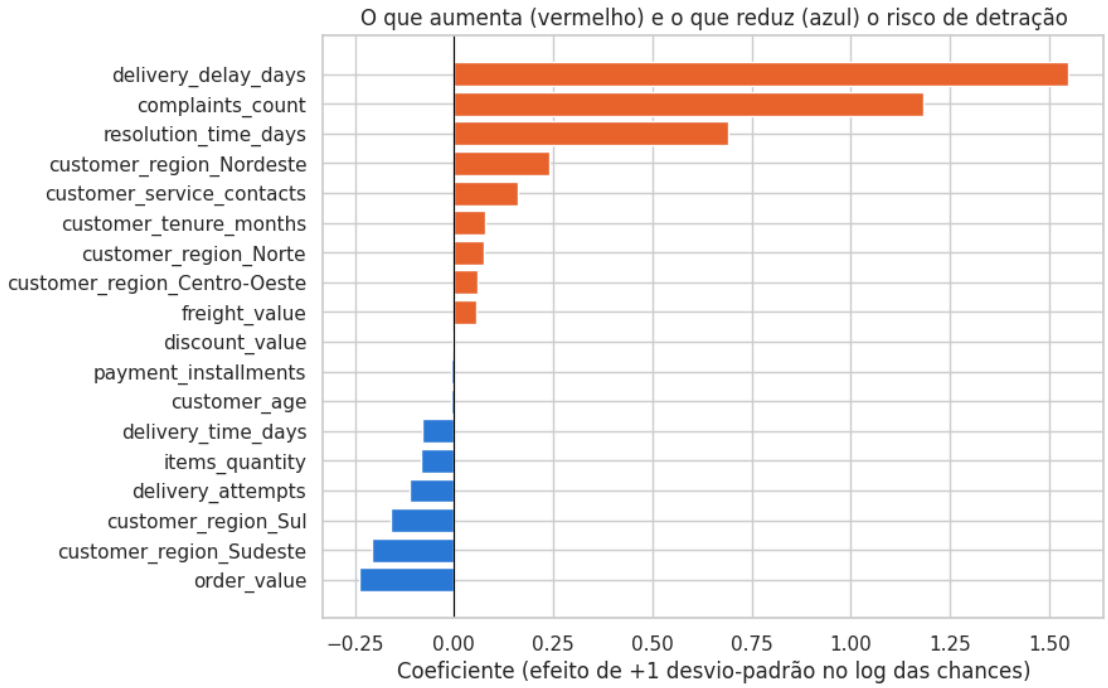


Figura — Coeficientes da Regressão Logística (efeito de +1 desvio-padrão). Vermelho aumenta o risco; azul reduz.

Fator	Razão de chances*	Leitura
Dias de atraso	**4,7**	Cerca de 1,5 dia a mais de atraso multiplica as chances de detração por quase 5
Reclamações	**3,3**	Cerca de 1,8 reclamação a mais
Tempo de resolução	**2,0**	Cerca de 3,5 dias a mais para resolver
Contatos com o SAC	1,2	Pouco efeito quando as reclamações já estão no modelo
Perfil, preço e pagamento	≈ 1,0	Idade, tempo de casa, desconto, parcelas e frete praticamente não pesam

** Efeito de aumentar a variável em 1 desvio-padrão, mantendo as demais constantes. Acima de 1 aumenta o risco.*

Uma árvore de decisão rasa, usada só para comunicar o modelo, traduz o resultado em regras: pedidos com **3 ou mais reclamações e 3 ou mais dias de atraso** são **34,9% da base**, com **99,1% de detratores**; o único grupo majoritariamente satisfeito (até 1 reclamação e até 2 dias de atraso) reúne apenas **5,4%** dos pedidos. O modelo confirma a EDA: a insatisfação vem da **operação**, não do perfil do cliente nem do preço.

Ponto de corte, custo do erro e lift

O modelo entrega um **score**, não um veredito. O corte que transforma o score em ação é uma decisão de negócio:

Corte	Pedidos acionados	Precisão	Recall	Alarmes falsos	Detratores fora da lista
0,50	91,0%	88,6%	95,5%	52	19
0,70	84,8%	90,8%	91,2%	39	37
0,85	73,2%	94,0%	81,5%	22	78
0,90	**64,2%**	**96,6%**	**73,5%**	**11**	**112**

Corte	Pedidos acionados	Precisão	Recall	Alarmes falsos	Detratores fora da lista
0,95	49,0%	99,2%	57,6%	2	179

Conjunto de teste (500 pedidos, 422 detratores).

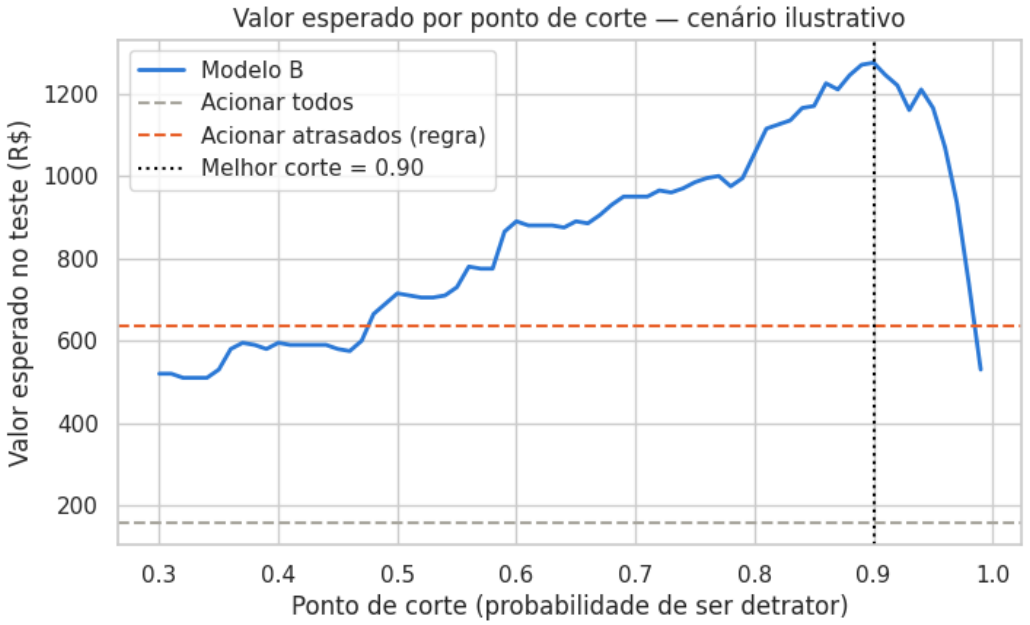


Figura — Valor esperado por ponto de corte em um cenário ilustrativo (custo da ação R$ 25; cliente recuperado vale R$ 150; a ação reverte 20% dos detratores).

- **Com valores hipotéticos**, acionar todos os pedidos fica quase no zero a zero (R$ 160 nos 500 pedidos do teste), acionar só os atrasados gera R$ 635 e o **modelo no corte de 0,90 gera R$ 1.275**, cerca de **2 vezes** a regra. O ganho vem de concentrar a ação onde o risco é muito alto e não gastar com quem já está satisfeito. Os valores reais devem vir da área de negócio.
- **Lift:** como 84,4% dos pedidos já são detratores, o lift máximo possível é **1,18**. Os 30% de maior risco têm 100% de detratores (lift de 1,185, o teto), e o modelo fica colado no modelo perfeito até 50% dos pedidos. A maior utilidade está na outra ponta: nos 10% de menor risco, só 46% são detratores. O modelo é muito bom em dizer **quem não precisa de ação**.

Complemento: prevendo a nota

Uma Regressão Linear com as mesmas variáveis erra a nota, em média, em **1,36 ponto** (MAE; RMSE de 1,72; R^2 de 0,52), contra 2,0 pontos de quem chuta sempre a média. A Árvore de Decisão ficou pior (MAE de 1,47; R^2 de 0,44). Com erro de 1,36 ponto perto da fronteira de 7, a nota prevista serve para **estimar o NPS esperado** de um lote de pedidos, mas o score de probabilidade é o mais adequado para decidir quem acionar.

5.4. Aplicabilidade: como a empresa usaria o modelo

1. **Na entrega, usar a regra simples já.** Como o cenário A não supera a regra, todo pedido com 1 dia ou mais de atraso entra em alerta imediatamente, sem precisar de modelo.
2. **No pós-venda, pontuar os pedidos todos os dias.** O pipeline completo (preparação + modelo) foi salvo em um arquivo de 5,1 KB. Um processo diário carrega o arquivo, calcula o risco dos pedidos em andamento e envia ao SAC/CRM uma lista ordenada do maior para o menor risco.
3. **Converter o risco em ação por faixa**, conforme a tabela abaixo.
4. **Explicar cada alerta.** Junto com o score, mostrar os motivos principais (por exemplo, "3 dias de atraso + 4 reclamações"), usando os coeficientes e as regras da árvore.

5. **Monitorar e retreinar.** Acompanhar a AUC, a taxa real de detratores em cada faixa e mudanças no perfil dos pedidos (data drift), com retreino periódico e um grupo de controle sem intervenção.

Faixa de risco	Score	% dos pedidos (teste)	Detratores reais	Ação sugerida
Alto	≥ 0,90	64,2%	**96,6%**	Contato ativo do SAC + compensação
Médio	0,70 a 0,90	20,6%	**72,8%**	Aviso proativo por mensagem com novo prazo
Baixo	< 0,70	15,2%	**48,7%**	Fluxo padrão

As faixas separam bem os pedidos. Os limites (0,70 e 0,90) são parâmetros de negócio, a ajustar à capacidade do SAC e aos custos reais.

Como a faixa Alto concentra 64% dos pedidos, se o SAC não tiver capacidade para todos, a lista é cortada pelo topo do ranking (os maiores scores primeiro). **Uso a evitar:** o score nunca deve ser usado para escolher quem recebe a pesquisa de NPS; isso inflaria o indicador sem melhorar a experiência.

5.5. Benefícios esperados

Benefício	Evidência no modelo	Para quem
Agir antes da pesquisa	O risco é calculado durante a jornada, para 100% dos pedidos, inclusive de quem nunca responde à pesquisa	SAC, CRM
Priorizar melhor que a regra atual	AUC de 0,868 contra 0,784 da regra de atraso; precisão de 96,6% no corte de 0,90	Gerência de operações
Economizar orçamento de compensação	Nos 10% de menor risco, menos da metade é detratora; no cenário ilustrativo, o corte de 0,90 gera cerca de 2× o valor da regra	Finanças, CRM
Decisões explicáveis	Coeficientes e regras mostram por que cada pedido foi sinalizado (atraso, reclamações, resolução)	Gestores, SAC
Foco na causa raiz	O modelo confirma que prazo e atendimento pesam e que perfil e preço não; orienta investimento em logística e SLA de resolução	Diretoria, Logística
Medir o efeito das ações	O score define os pedidos elegíveis para o teste A/B do aviso proativo (meta: detratores entre atrasados de 88% para 83%)	Experiência do cliente

> **Em resumo:** o modelo não resolve sozinho um NPS de −80, porque a insatisfação é sistêmica. Ele é a **ferramenta de priorização** enquanto a causa (prazo descumprido e resolução lenta) é corrigida: indica onde agir primeiro, onde não gastar, e permite medir se as ações funcionam.

5.6. Limitações do modelo

- **Dados com sinais de simulação:** em dados reais, o desempenho tende a ser menor que o observado aqui.
- **Momento das variáveis de atendimento não confirmado:** se as reclamações forem registradas depois da pesquisa, o cenário B tem vazamento e só vale a regra de atraso. É o primeiro ponto a validar com o SAC.
- **Sem datas:** não foi possível validar o modelo de forma temporal (treinar no passado e testar no futuro) nem avaliar sazonalidade.

- **Amostra de teste pequena para a classe minoritária** (78 não detratores) e **valores financeiros hipotéticos** na análise de ponto de corte.
- **Calibração:** na faixa Médio, o modelo superestima o risco (82,7% previsto contra 72,8% real); as probabilidades devem ser calibradas antes do deploy.
- **Associação não é causa:** o modelo indica quem está em risco, mas só o teste A/B prova que a ação proativa reduz detratores.

Considerações finais

As cinco partes formam uma linha única de raciocínio. O **problema de negócio** (Parte 1) é descobrir onde a jornada gera detratores. O **alvo** (Parte 2) é a nota de NPS, tratada como condição de detrator. A **EDA** (Parte 3) mostrou que o vilão é a **promessa de prazo quebrada**, agravada por reclamações, com rupturas claras no 1º e no 3º dia de atraso e na 2ª reclamação: as hipóteses sobre entrega e atendimento foram confirmadas, e as sobre preço, perfil e região, refutadas. A **estratégia preditiva** (Parte 4) transforma esse aprendizado em ação: um escore de risco de detrator, atualizado durante a entrega, que permite agir antes da pesquisa, com o valor da ação comprovado por teste A/B. O **modelo implementado** (Parte 5) confirma o caminho: na entrega, a regra de atraso já basta; com os dados do atendimento, a Regressão Logística ordena os pedidos por risco com AUC de 0,868 e concentra a ação onde ela vale mais.

- **Questões a validar com o negócio:** em que momento a pesquisa é disparada; a ordem dos eventos de atendimento em relação à pesquisa; por que a nota tem casas decimais; e como a coluna de recompra foi gerada.
- **Próximos passos:** validar o momento de registro das reclamações, obter as datas dos pedidos para validação temporal, definir com o negócio custos reais e capacidade do SAC para fixar o ponto de corte, calibrar as probabilidades e rodar o teste A/B do aviso proativo usando o score.